

# Hadoop离线大数据分析

初识Hadoop

贝毅君 beiyj@zju.edu.cn





What Is Apache Hadoop?

The Apache™ Hadoop® project develops open-source software for reliable, scalable, distributed computing.

解决问题:

海量数据的存储(HDFS) 海量数据的分析(MapReduce) 资源管理调度(YARN)

作者:Doug Cutting

受Google三篇论文的启发(GFS、MapReduce、BigTable(Hbase))

#### Hadoop生态圈







#### Ambari

Provisioning, Managing and Monitoring Hadoop Clusters



og Collector





Norkflow Oozie



Scripting



R Connectors Statistics



Columnar Hbase

#### YARN Map Reduce v2

Distributed Processing Framework



的分布式计算 Hbase: 分布式nosql数据库

HDFS: 分布式海量数据存储

YARN mapreduce:解决海量数据

Hive:数据仓库工具,使用类似于 SQL的语言实现快速数据分析,国 内使用较多

Pig: 类似于hive,但使用的语法和 标准SQL差距较大,国外使用较多

Mahout: 机器学习工具

Flume: 自动化日志采集工具

Sqoop: Hadoop与关系数据库之间 的数据交换工具

Oozie: 串联所有分析流程的工作 流工具

Zookeeper: 分布式应用程序协调 服务

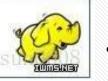




**HDFS** 

Hadoop Distributed File System p://blog.csdn.net/kisssi







### **Hadoop Distributed File System**



数据量越来越多,在一个操作系统管辖的范围 存不下,那么就分配到 更多操作系统管理的磁 盘中。但不方便管理和 维护,因此需要一种管 理多台机器上文件的系 统,这就是分布式文件 管理系统 (DFS)。



通透性。让实际上是通过网络来访问文件的动作,由程序与用户看来,就像是访问本地的磁盘一样。

容错。即使系统中有某些节点脱机,整体来说系统仍然可以持续运作而不会有数据损失。



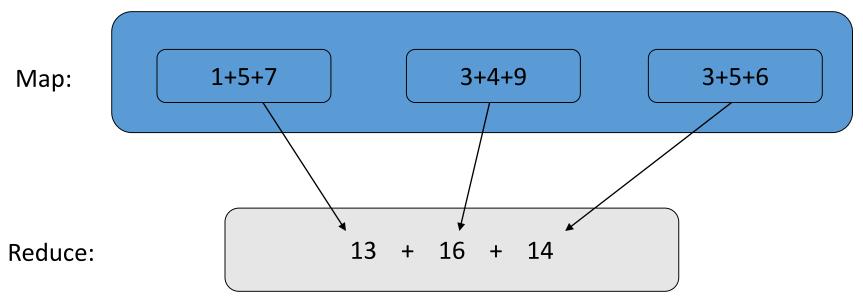
分布式文件管理系统很多,hdfs只是其中一种。 适用于一次写入多次查询的情况,不支持并发写情况,小文件不合适。 对于需要频繁写入的小文件,更适合用Hbase 进行存储。

### mapreduce 介绍



### 怎么解决海量数据的计算:分而治之

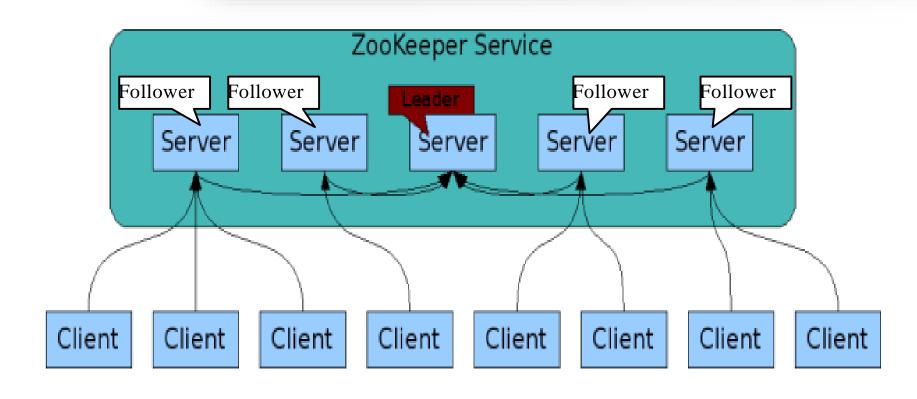
求和: 1+5+7 +3+4+9 +3+5+6=?



- MapReduce是一种 分布式计算模型, 由Google提出,主 要用于搜索领域, 解决海量数据的计 算问题.
  - MR由两个阶段组成: Map和Reduce,即 可实现分布式计算。
- 这两个函数的形参 是key、value对,表 示函数的输入信息。

### zookeeper介绍





- Zookeeper 是 Google 的 Chubby一个开源的实现,是 Hadoop 的分布式协调服务。
- 它包含一个简单的原语集,分布式应用程序可以基于它实现同步服务,配置维护和命名服务等。
- 提供通用的分布式锁服务,用以协调分布式应用。
- Hadoop2.0使用Zookeeper的事件处理确保整个集群只有一个活跃的NameNode,存储配置信息等。
- HBase使用Zookeeper的事件处理确保整个集群只有一个Hmaster,察觉HRegionServer联机和宕机,存储访问控制列表等。



#### Hbase

HBase – Hadoop Database , 是一个高可靠性、高性能、面向列、可伸缩的分布式存储系统 , 利用HBase技术可在廉价PC Server上搭建起大规模结构化存储集群。HBase利用Hadoop HDFS作为其文件存储系统 , 利用Hadoop MapReduce来处理HBase中的海量数据 , 利用Zookeeper作为协调工具。

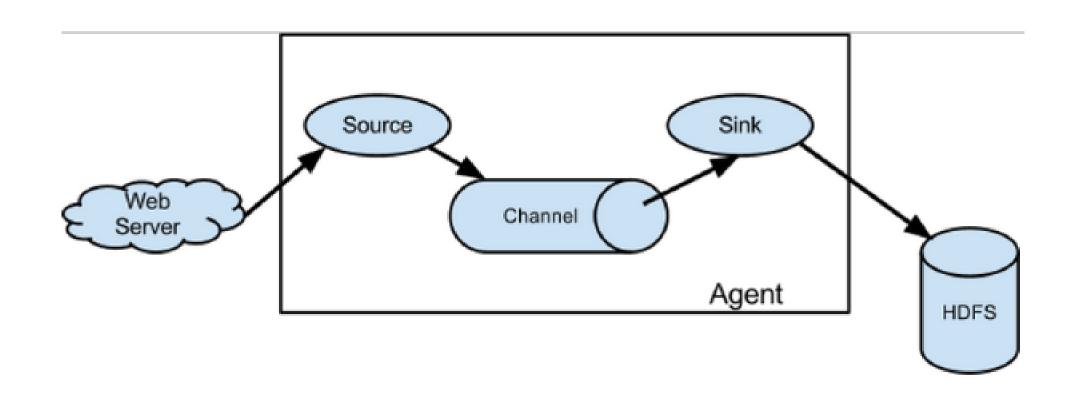


#### Hive

Hive是基于Hadoop的一个数据仓库工具,可以将结构化的数据文件映射为一张数据库表,并提供简单的sql查询功能,可以将sql语句转换为MapReduce任务进行运行。 其优点是学习成本低,可以通过类SQL语句快速实现简单的MapReduce统计,不必开发专门的MapReduce应用,十分适合数据仓库的统计分析。

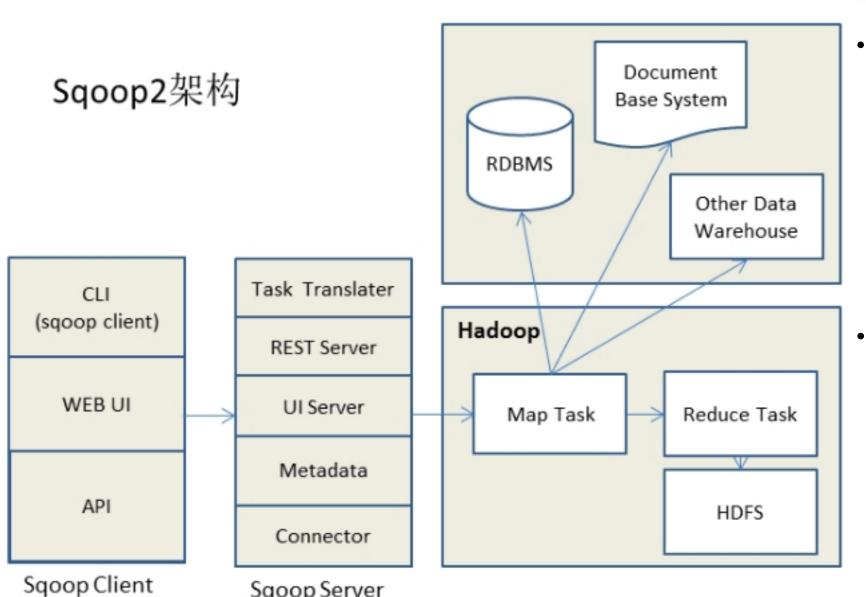
### Flume介绍





• Flume是分布式的日志收集系统,它将各个服务器中的数据收集起来并送到指定的地方。



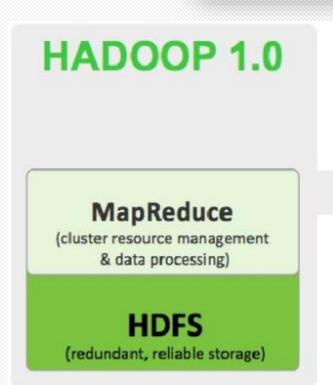


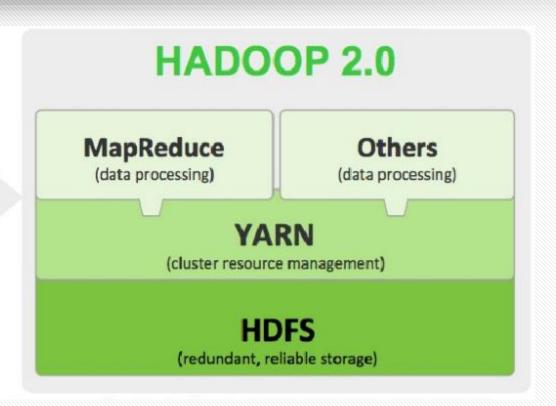
Sqoop Server

- Sqoop主要用来在Hadoop 和关系数据库中传递数据。 通过Sqoop,可以方便地 将数据从关系数据库导入 到HDFS,或者将数据从 HDFS导出到关系数据库。
- Sqoop架构非常简单,其 整合了Hive、Hbase和 Oozie,通过map-reduce任 务来传输数据,从而提供 并发特性和容错。

#### Hadoop1.0与2.0







YARN的引人

全新的资源管理器,将资源管理和处理组件分开。基于 YARN 的架构不受 MapReduce 约束,在YARN上可以使用其他计算框架(如spark),大大减少耦合。



Hadoop2.0在1.0版本的基础上,对 common中HDFS等的架构进行答复改进, 大幅提升速度与可用性。



### 本地模式

等同于单机计算模式

### 伪分布式

使用一台机器模拟分布式集群

### 集群模式

由多台机器组成的真实集群(推荐)



#### 机器数量选择

尽量选择奇数个机器(3,5,7) 具体原因在zookeeper详细介绍 中说明



#### 每台机器上启动的进程

根据每台机器需要在集群中承担的任务角色合理开启每台机器上的任务进程(zk在每台机器上都要启动)



#### 使用SSH

使用SSH免登陆保证机器之间的 通讯



## THE END